

PUC Minas | 2026

Red Teaming Automatizado de Large Language Models em Domínios Críticos: Uma Abordagem de Avaliação de Vulnerabilidades Domain-Aware

Alunos: Kaio H Silveira, Pedro A. Oliveira

Orientadores: Cleiton Silva Tavares, Danilo de Quadros Maia Filho, João Pedro Oliveira Batisteli, Leonardo Vilela Cardoso

Sumário

1. Área
2. Problema
3. Justificativa e Relevância
4. Objetivo Geral e Específicos
5. Trabalhos Relacionados
6. Materiais e Métodos
7. Metodologia
8. Agradecimento

Área

Segurança de software não para na fronteira do código, ela se estende aos modelos que o software executa.

- Engenharia de Software fornece os fundamentos: qualidade, testes, confiabilidade e manutenção de sistemas
- Red teaming automatizado é uma prática de teste de segurança semelhante a testes de penetração em software tradicional
- Jailbreaking: estratégias adversariais que exploram falhas de alinhamento dos modelos, comprometendo a confiabilidade do sistema
- A pesquisa aplica princípios de ES: automação, experimentação controlada e métricas para avaliar LLMs como componentes críticos de software

Problema

- **Gravidade Assimétrica:** A literatura foca em vulnerabilidades genéricas, ignorando que um jailbreak que gera um diagnóstico falso é um risco à vida, enquanto um insulto é apenas um erro ético.
- **Lacuna de Contexto:** Queries genéricas não capturam as nuances semânticas e regulatórias de domínios específicos como Saúde e Finanças

Como a eficácia de ataques de jailbreak varia entre domínios críticos e em que medida as defesas atuais são insuficientes nesses contextos?

Justificativa & Relevância

Impactos em domínios críticos

→ **Saúde:** Diagnósticos incorretos e prescrições perigosas que geram danos diretos à vida.

→ **Financeiro:** Recomendações de risco e manipulação de dados resultando em prejuízos massivos.

→ **Jurídico:** Orientações inadequadas que levam à violação de direitos fundamentais.

92,4%

ASR

TAXA DE SUCESSO NO
LLAMA2)

2.0 X

AUMENTO DE
VULNERABILIDADE
MULTI-TURN

Objetivos

Objetivo Geral: Avaliar vulnerabilidades de LLMs via red teaming automatizado domain-aware em domínios críticos.

Objetivos Específicos:

01



Desenvolvimento: Conceber um dataset de queries adversariais com critérios de violação específicos para saúde, finanças e direito.

02



Diagnóstico: Caracterizar o trade-off entre a utilidade do modelo e a robustez das defesas em contextos de alta criticidade.

Objetivos

Objetivo Geral: Avaliar vulnerabilidades de LLMs via red teaming automatizado domain-aware em domínios críticos.

Objetivos Específicos:

03



Avaliação: Analisar a eficácia comparativa de três famílias de ataque (Prompt, Otimização e Multi-turn) em modelos especializados.

04



Síntese: Estabelecer diretrizes de mitigação baseadas em vulnerabilidades identificadas por domínio

Trabalhos Relacionados

Niloy et al. (2025) — IEEE COMPAS

- Taxonomia de 4 famílias de ataque em LLMs
- ASR de até 92,4% com ataques de otimização
- ⚠ Limitação: queries genéricas, sem distinção de domínio

Knowlton et al. (2026) — IEEE Transactions on AI

- Survey abrangente de ataques e defesas prompt-based
- ⚠ Evidencia lacuna: ataques de otimização em domínios críticos são campo aberto

Materiais e Métodos

Modelos e domínios

Domínio Crítico	Modelo Open-Source	Modelo Closed-Source
Saúde	MedLLaMA	Med-PaLM 2
Financeiro	FinMA	BloombergGPT
Jurídico	SaulLM-7B	GPT-4

Métricas

1. ASR

2. Stealthiness


3. Transferability

4. FPR (False Positive Rate)

Metodologia

11

Metodologia de Red Teaming Automatizado Domain-Aware em LLMs Críticos



Metodologia

Fluxo e Resultados

11

Ciclo experimental

01. Preparação do Dataset
DomainAware

02. Execução do Red
Teaming Automatizado

03. Ciclo de Ataques e
Refinamento

04. Análise CrossDomínio e
CrossModelo

MATRIZ DE CONFUSÃO (ASR %)

	Success	Partial	Failure
LLaMA-2	92	5	3
Vicuna	84	10	6
ChatGPT-4	65	20	15

0% 100%

Obrigado!