

PUC Minas | 2026

Red Teaming Automatizado de Large Language Models em Domínios Críticos: Uma Abordagem de Avaliação de Vulnerabilidades Domain-Aware

Alunos: Kaio H Silveira, Pedro A. Oliveira

Orientadores: Cleiton Silva Tavares, Danilo de Quadros Maia Filho, João Pedro Oliveira Batisteli, Leonardo Vilela Cardoso



Sumário

1. Área
 2. Problema
 3. Justificativa e Relevância
 4. Objetivo Geral e Específicos
 5. Trabalhos Relacionados
 6. Materiais e Métodos
 7. Metodologia
 8. Agradecimento
- 

Área

LLMs estão deixando de ser ferramentas experimentais e se tornando infraestrutura crítica.

- LLMs (GPT-4, Claude, LLaMA-2) adotados em aplicações de alto impacto
- Uso crescente em saúde, financeiro e jurídico
- **Jailbreaking:** estratégias adversariais que contornam proteções dos modelos
- Red teaming automatizado: identificação sistemática de vulnerabilidades em escala

Problema

A literatura sabe que LLMs são vulneráveis, mas não sabe o quanto isso muda quando o modelo é um médico, um advogado ou um consultor financeiro.

- Estudos existentes avaliam LLMs com queries genéricas
- Foco predominante em ataques prompt-based
- Ataques de otimização — os mais eficazes — pouco explorados em domínios críticos

LLMs apresentam vulnerabilidades distintas em domínios críticos, e as defesas existentes são suficientemente eficazes nesses contextos?

Justificativa & Relevância

Um modelo comprometido em um domínio crítico não é só um problema técnico, é um risco real para pessoas

- Ataques de otimização: até 92,4% de ASR no LLaMA-2
- Multi-turn: ASR quase dobra em apenas 8 turnos de conversa
- Impacto concreto em domínios críticos:
 - **Diagnósticos incorretos** → danos à saúde
 - **Recomendações de risco** → prejuízos financeiros
 - **Orientações inadequadas** → violação de direitos
- Nenhum estudo avalia vulnerabilidades de forma domain-aware

Objetivos

Objetivos pensados para preencher uma lacuna que a literatura ainda não fechou.

Objetivo Geral: Avaliar vulnerabilidades de LLMs via red teaming automatizado domain-aware em domínios críticos

Objetivos Específicos:

- Construir dataset de queries adversariais com critérios de violação por domínio
- Aplicar 3 famílias de ataque: prompt-based, optimization-based e multi-turn
- Comparar ASR entre domínios (saúde, financeiro, jurídico) e entre modelos
- Propor diretrizes de mitigação domain-aware

Trabalhos Relacionados

Niloy et al. (2025) — IEEE COMPAS

- Taxonomia de 4 famílias de ataque em LLMs
- ASR de até 92,4% com ataques de otimização
- ⚠ Limitação: queries genéricas, sem distinção de domínio

Knowlton et al. (2026) — IEEE Transactions on AI

- Survey abrangente de ataques e defesas prompt-based
- ⚠ Evidencia lacuna: ataques de otimização em domínios críticos são campo aberto

Materiais e Métodos

Modelos especializados, ataques sistemáticos e métricas rigorosas — porque o contexto importa.

1. **Modelos especializados por domínio:**

a. Saúde → MedLLaMA (open) · Med-PaLM 2 (closed)

b. Financeiro → FinMA (open) · BloombergGPT (closed)

c. Jurídico → SaulLM-7B (open) · GPT-4 (closed)

2. **Dataset:** queries adversariais anotadas com critérios de violação por domínio

3. **Famílias de ataque:** prompt-based, optimization-based (GCG) e multi-turn

4. **Métricas:** ASR · Transferabilidade · Stealthiness · FPR

Metodologia



1. **Preparação e Dataset** — critérios de violação ajustados por domínio crítico
2. **Execução do Red Teaming** — 3 tipos de ataque sobre pares open/closed por domínio
3. **Ciclo de Ataques e Refinamento** — loop iterativo com registro de ASR
4. **Análise e Resultados** — comparação cross-domínio e cross-modelo + mitigações



Obrigado!

