

Red Teaming Automatizado de Large Language Models em Domínios Críticos: Uma Abordagem de Avaliação de Vulnerabilidades Domain-Aware

Kaio Henrique Silveira¹, Pedro Arthur Oliveira Silva¹

¹Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brasil

{kaio.silveira, pedro.arthur}@sga.pucminas.br

Abstract. *The growing adoption of Large Language Models (LLMs) in critical software systems, notably in healthcare, finance, and legal domains, poses new challenges to security engineering. This work proposes an experimental domain-aware automated red teaming approach for systematic vulnerability assessment of LLMs, using three attack families: prompt-based, optimization-based (GCG), and multi-turn. The study fine-tunes open-source models via LoRA into domain specialists, which serve as surrogates for generating GCG attacks later transferred to publicly accessible closed-source models, measuring Attack Success Rate (ASR), Transferability Rate (TR), False Positive Rate (FPR), and Stealthiness Score. The central differentiator is the definition of domain-specific violation criteria prior to attack execution, enabling unprecedented cross-domain and cross-model comparison. Expected contributions include a domain-specific adversarial dataset, quantitative vulnerability analysis, and context-calibrated mitigation guidelines.*

Resumo. *A crescente adoção de Large Language Models (LLMs) em sistemas de software críticos, notadamente nos domínios da saúde, finanças e direito, impõe novos desafios à engenharia de segurança. Este trabalho propõe uma abordagem experimental de red teaming automatizado domain-aware para avaliação sistemática das vulnerabilidades de LLMs nesses contextos, utilizando três famílias de ataque: prompt-based, optimization-based (GCG) e multi-turn. O estudo realiza fine-tuning via LoRA em modelos open-source, que servem de surrogate para gerar ataques GCG posteriormente transferidos a modelos closed-source de fornecedores distintos, mensurando ASR, TR, FPR e Stealthiness Score. O diferencial central é a definição de critérios de violação específicos por domínio antes da execução dos ataques, permitindo comparação cross-domain e cross-model inédita na literatura. Espera-se contribuir com um dataset adversarial domain-specific, análise quantitativa das assimetrias de vulnerabilidade e diretrizes de mitigação calibradas por contexto.*

Bacharelado em Engenharia de Software - PUC Minas
Trabalho de Conclusão de Curso (TCC)

Orientador de conteúdo (TCC I): Danilo Maia - danilomaia@pucminas.br
Orientador de conteúdo (TCC I): João Pedro Batisteli - joabatisteli@pucminas.br
Orientador de conteúdo (TCC I): Leonardo Vilela - leonardocardoso@pucminas.br
Orientador acadêmico (TCC I): Cleiton Tavares - cleitontavares@pucminas.br
Orientador acadêmico (TCC II): (a ser definido)

Belo Horizonte, 21 de Julho de 2026.

1. Introdução

Os Modelos de Linguagem de Grande Escala (do inglês, *Large Language Models*, LLMs), como GPT-4, Claude e LLaMA-2, têm demonstrado capacidade notável na geração e compreensão de linguagem natural, sendo progressivamente adotados em aplicações de alto impacto [Niloy et al. 2025]. Baseados na arquitetura *Transformer* [Vaswani et al. 2017], esses modelos são treinados em corpora massivos e ajustados por meio de técnicas de alinhamento como o Aprendizado por Reforço com Retroalimentação Humana (do inglês, *Reinforcement Learning from Human Feedback*, RLHF) [Ouyang et al. 2022]. Paralelamente, cresce o interesse pela avaliação de sua segurança, especialmente no que diz respeito a técnicas de *jailbreaking*, estratégias adversariais que contornam os mecanismos de segurança dos modelos para induzir a geração de conteúdo nocivo [Knowlton et al. 2026]. A prática de *red teaming* automatizado tem se consolidado como abordagem sistemática de identificação dessas vulnerabilidades, substituindo esforços manuais por *pipelines* algorítmicos capazes de gerar e iterar sobre *prompts* adversariais em escala [Goh et al. 2025].

Os estudos existentes, no entanto, apresentam duas limitações centrais. Em primeiro lugar, conduzem avaliações com *queries* genéricas, sem distinção do contexto de aplicação do modelo. Em segundo lugar, concentram-se predominantemente em ataques baseados em *prompt*, deixando pouco explorada a avaliação de ataques baseados em otimização, que alcançam taxas de sucesso (*Attack Success Rate*, ASR) de até 92,4% em modelos como o LLaMA-2, significativamente superiores às demais famílias de ataque [Niloy et al. 2025]. Diante disso, este trabalho investiga duas questões de pesquisa (do inglês, *Research Questions*, RQ): **RQ01: Como a taxa de sucesso de ataques adversariais automatizados varia entre os domínios de saúde, financeiro e jurídico em modelos especializados?** **RQ02: As defesas existentes são suficientemente eficazes em domínios críticos, considerando o *trade-off* entre ASR e FPR em cada contexto?**

A relevância desse problema é sustentada pelo impacto que vulnerabilidades em domínios críticos podem causar. No domínio da saúde, chatbots baseados em LLMs são empregados para triagem de pacientes, orientação farmacêutica e apoio a diagnósticos [Singhal et al. 2023]; no domínio financeiro, para análise de risco, assessoria de investimentos e detecção de fraudes [Yang et al. 2023]; no domínio jurídico, para revisão de contratos e orientação legal [Nay et al. 2023]. Demonstra-se que ataques de otimização atingem até 92,4% de ASR no LLaMA-2 e que ataques *multi-turn* praticamente dobram o ASR entre o segundo e o oitavo turno, de 28,5% para 64,2%, vetor especialmente crítico em sistemas conversacionais médicos e jurídicos [Niloy et al. 2025]. Mecanis-

mos de defesa como *anomaly detection*, embora reduzam o ASR em aproximadamente 44%, introduzem uma taxa de falsos positivos de 8,2%, inaceitável em sistemas de saúde reais [Niloy et al. 2025]. Adicionalmente, ataques de injeção indireta de *prompt* demonstram que aplicações reais integradas a LLMs são comprometidas por entradas adversariais presentes no ambiente de execução, não apenas nos *prompts* diretos do usuário [Greshake et al. 2023].

O objetivo geral deste trabalho é avaliar vulnerabilidades de LLMs por meio de *red teaming* automatizado *domain-aware* em domínios críticos. Para tanto, definem-se os seguintes objetivos específicos: (i) identificar vulnerabilidades em LLMs especializados nos domínios de saúde, finanças e direito por meio de ataques adversariais automatizados; (ii) caracterizar o *trade-off* entre a utilidade do modelo e a robustez das defesas em contextos de alta criticidade; e (iii) analisar a eficácia comparativa de três famílias de ataque, *prompt-based*, *optimization-based* (GCG) e *multi-turn*, em modelos especializados por domínio, obtidos por meio de *fine-tuning* via LoRA e utilizados como *surrogate* para os ataques GCG transferidos aos modelos *closed-source*.

Como resultados esperados, este trabalho visa: (a) conceber um *dataset* adversarial *domain-specific*, com critérios de violação calibrados por domínio antes da execução dos experimentos; (b) uma análise quantitativa das assimetrias de vulnerabilidade entre saúde, finanças e jurídico, expressa como uma matriz de ASR de $3 \text{ domínios} \times 3 \text{ famílias} \times N \text{ modelos}$; (c) evidências sobre a transferibilidade de ataques *domain-specific* entre modelos *open-source* e *closed-source* por meio de *surrogate transfer*; e (d) um conjunto de diretrizes de mitigação contextualizadas por domínio, incluindo limiares de FPR diferenciados e estratégias de *anomaly detection* contextual [Goh et al. 2025].

O restante deste artigo está organizado da seguinte forma. A Seção 2 apresenta a fundamentação teórica sobre LLMs, mecanismos de alinhamento e técnicas adversariais. A Seção 3 discute os trabalhos relacionados. A Seção 4 descreve os materiais e métodos empregados. Por fim, a Seção 5 apresenta as considerações finais.

2. Fundamentação Teórica

Esta seção apresenta os conceitos e mecanismos consolidados que fundamentam a pesquisa, abordando a arquitetura dos LLMs, os mecanismos de alinhamento, as técnicas adversariais de *jailbreaking* e as métricas de avaliação adotadas. Tais conceitos são necessários para a compreensão das contribuições metodológicas propostas nas seções seguintes.

2.1. Large Language Models e Mecanismos de Alinhamento

Os LLMs são modelos de linguagem de grande escala baseados na arquitetura *Transformer* [Vaswani et al. 2017], que utiliza mecanismos de atenção para capturar dependências de longo alcance em sequências textuais. Modelos como o GPT-4o [OpenAI 2023], o Claude 3.5 Sonnet e o LLaMA-2 [Touvron et al. 2023] são pré-treinados em corpora de bilhões de *tokens* e subsequentemente ajustados para tarefas específicas por *fine-tuning* supervisionado e por técnicas de alinhamento. Esse processo de pré-treinamento confere aos modelos capacidade generalizável de compreensão e geração de linguagem natural, enquanto o *fine-tuning* direciona o comportamento do modelo para um domínio ou tarefa específica. Modelos especializados como MedLLaMA (saúde), FinMA (financeiro)

e SaulLM-7B (jurídico) são exemplos públicos desse processo. Esta pesquisa realiza seu próprio processo de *fine-tuning domain-specific* sobre modelos *open-source* de base, utilizando a técnica de *Low-Rank Adaptation* (LoRA) [Hu et al. 2022], que ajusta uma fração reduzida dos parâmetros do modelo em vez de retreinar a totalidade de seus pesos, tornando o processo computacionalmente viável em GPUs de uso acadêmico. Essa abordagem permite comparar diretamente o mesmo modelo base antes e depois do *fine-tuning domain-specific*, isolando o efeito da especialização sobre a vulnerabilidade a ataques adversariais.

O RLHF [Ouyang et al. 2022], base do alinhamento em modelos como o GPT-4o, ajusta o modelo com base em preferências humanas expressas como recompensas, penalizando respostas indesejadas. O *Constitutional AI* (CAI) [Bai et al. 2022], desenvolvido pela Anthropic e empregado no Claude 3.5 Sonnet, complementa o RLHF ao treinar o modelo para seguir um conjunto de princípios éticos, empregando o próprio modelo para auto-avaliar e refinar suas respostas. O Gemini 1.5 Pro, por sua vez, emprega um processo de alinhamento próprio desenvolvido pelo Google. Embora essas abordagens aumentem a robustez de *baseline* dos modelos, não generalizam adequadamente contra adversários adaptativos, em especial os baseados em otimização [Zou et al. 2023]. Os modelos *closed-source* são avaliados nesta pesquisa em seu estado nativo, isto é, com o alinhamento já realizado por cada fornecedor, sem qualquer *fine-tuning* adicional realizado pelos autores, uma vez que nenhum dos três fornecedores oferece, em 2026, acesso público e irrestrito a mecanismos de *fine-tuning* para seus modelos mais recentes. A comparação entre esses três mecanismos de alinhamento nativo distintos frente aos ataques transferidos dos modelos *open-source* fine-tunados constitui uma das contribuições originais desta pesquisa.

2.2. Red Teaming Automatizado e Jailbreaking em LLMs

Red teaming é uma prática de segurança em que uma equipe adversarial tenta identificar vulnerabilidades de um sistema antes que atores maliciosos o façam [Perez et al. 2022]. Em LLMs, o *red teaming* automatizado emprega algoritmos para gerar e iterar sobre *prompts* adversariais em escala, sem depender de esforço humano por tentativa, analogamente aos testes de penetração (*pentesting*) em *software* tradicional. Essa analogia é particularmente relevante para a Engenharia de Software, pois posiciona a avaliação de segurança de LLMs como uma extensão natural das práticas de garantia de qualidade e segurança de sistemas.

O *jailbreaking* é a técnica adversarial que contorna as salvaguardas de segurança do LLM por meio de *prompts* especialmente construídos, operando no espaço semântico da linguagem natural. Greshake et al. [Greshake et al. 2023] demonstram que ataques de injeção indireta de *prompt* comprometem aplicações reais integradas a LLMs por meio de entradas adversariais presentes no ambiente de execução, não apenas nos *prompts* diretos do usuário, ampliando consideravelmente a superfície de ataque.

Em 2023, Zou propõe o algoritmo *Greedy Coordinate Gradient* (GCG), que busca sufixos adversariais em nível de *token* que maximizam a probabilidade do modelo gerar conteúdo proibido, com perturbações controladas ($\epsilon \leq 30$ *tokens*). O algoritmo opera de forma gananciosa: a cada iteração, seleciona a substituição de *token* que maximiza o gradiente da função de perda em direção à resposta proibida. Por ser um ataque *white-box*,

o GCG requer acesso aos pesos e gradientes internos do modelo, sendo aplicável apenas a modelos *open-source*. Para avaliar modelos *closed-source* acessados via API, esta pesquisa adota a estratégia de *surrogate transfer*: sufixos adversariais gerados contra os modelos *open-source* especializados (fine-tunados pelos autores nos domínios de saúde, financeiro e jurídico) são transferidos e testados nos modelos *closed-source* (GPT-4o, Claude 3.5 Sonnet e Gemini 1.5 Pro) sem nenhum acesso adicional além da API pública [Zou et al. 2023], que demonstra que essa abordagem alcança taxa de transferência *cross-model* de 58,3%, validando sua viabilidade em cenários reais.

2.3. Taxonomia de Ataques e Métricas de Avaliação

A literatura consolida três principais famílias de ataque adversarial a LLMs relevantes para esta pesquisa [Niloy et al. 2025]: (i) *prompt-based*, que inclui *role-play*, inversão de instrução e manipulação de contexto, operando inteiramente no espaço semântico da linguagem natural sem modificação de *tokens*; (ii) *optimization-based*, baseada no algoritmo GCG para geração de sufixos adversariais otimizados em nível de *token* com *surrogate transfer* para modelos *closed-source*; e (iii) *multi-turn*, que explora múltiplos turnos de conversa para degradar progressivamente o alinhamento do modelo pelo acúmulo de contexto. Em 2025, Niloy demonstra que ataques *multi-turn* praticamente dobram o ASR entre o segundo e o oitavo turno de conversa, de 28,5% para 64,2%, evidenciando que o alinhamento se deteriora com o comprimento do diálogo.

As famílias de ataque diferem também em termos de *stealthiness*: ataques *prompt-based* tendem a produzir *prompts* mais naturais e difíceis de detectar automaticamente, enquanto sufixos GCG são visualmente incomuns mas altamente eficazes. Essa tensão entre eficácia e disfarce é particularmente relevante em domínios críticos, nos quais filtros automáticos devem equilibrar a detecção de ataques com a não rejeição de consultas legítimas de profissionais.

As métricas centrais de avaliação adotadas neste trabalho são: ASR (*Attack Success Rate*), proporção de *queries* adversariais que resultam em violação total da política do modelo; TR (*Transferability Rate*), proporção de ataques que funcionam em um modelo e se transferem para outro via *surrogate transfer* [Zou et al. 2023]; FPR (*False Positive Rate*), proporção de *queries* benignas incorretamente bloqueadas por mecanismos de defesa, métrica crítica em domínios como saúde, onde uma recusa indevida pode comprometer o atendimento de um profissional; e *Stealthiness Score*, escala de 1 a 5 que mede a semelhança do *prompt* adversarial com um *input* benigno, avaliada por anotadores humanos com concordância medida pelo coeficiente *Cohen's Kappa* [Niloy et al. 2025].

3. Trabalhos Relacionados

Os trabalhos relacionados a esta pesquisa organizam-se em duas categorias: estudos sobre taxonomias de ataques adversariais a LLMs e estudos sobre defesas e *surveys* do estado da arte. Para cada trabalho, identificam-se os elementos reutilizados nesta pesquisa, os aspectos comparados e as lacunas que esta proposta busca preencher.

Na categoria de taxonomias de ataques, o trabalho [Niloy et al. 2025], publicado no IEEE COMPAS, propõe uma taxonomia de quatro famílias de ataque adversarial a LLMs, *prompt-based*, *optimization-based*, *multi-turn* e LLM-to-LLM, reportando ASR de até 92,4% com ataques de otimização no LLaMA-2 e 65,1% no ChatGPT-4. Desta

pesquisa, reutilizam-se a taxonomia de ataques e as métricas de avaliação (ASR, FPR, TR), e comparam-se os resultados com os reportados pelos autores. A limitação central de Niloy et al. [Niloy et al. 2025] é o uso de *queries* genéricas sem critérios de violação diferenciados por domínio, lacuna que esta pesquisa se propõe a superar por meio da definição *a priori* de critérios domain-specific. O trabalho [Zou et al. 2023] introduz o algoritmo GCG e demonstram taxa de transferência *cross-model* de 58,3% com a estratégia de *surrogate transfer*, que esta pesquisa adota e estende para o contexto de domínios críticos, investigando se essa taxa se altera com ataques *domain-specific*.

Na categoria de defesas e *surveys*, Knowlton et al. [Knowlton et al. 2026], em *survey* publicado no IEEE Transactions on Artificial Intelligence, mapeiam o estado da arte em ataques e defesas *prompt-based* a LLMs, evidenciando que ataques de otimização em domínios críticos constituem campo ainda em aberto e que a maioria das defesas existentes é agnóstica de domínio. Desta pesquisa, reutiliza-se a caracterização das defesas *prompt-based* como linha de base comparativa; a lacuna identificada pelos autores quanto à ausência de avaliações *domain-aware* é precisamente o que esta proposta endereça. Shen et al. [Shen et al. 2024] caracterizam *jailbreaks* em produção em larga escala, identificando padrões de *prompts* adversariais recorrentes em ambiente real; desta pesquisa, reutiliza-se a tipologia de *prompts prompt-based* para a construção do *dataset* adversarial, comparando-se se tais padrões mantêm eficácia em domínios críticos especializados. O trabalho [Chao et al. 2025] propõe o método PAIR (*Prompt Automatic Iterative Refinement*) para *jailbreaking* de modelos *black-box* em até vinte *queries*; desta pesquisa, reutiliza-se a abordagem iterativa de refinamento de *prompts* presente na Fase 3 da metodologia, comparando-se sua eficácia com a do GCG em contextos de domínio crítico.

Em conjunto, esses estudos evidenciam a lacuna central que esta pesquisa preenche: a ausência de avaliação sistemática *domain-aware* que defina critérios de violação específicos por domínio, empregue tanto ataques *white-box* com *surrogate transfer* quanto ataques *black-box*, e permita comparações quantitativas entre saúde, finanças e jurídico em modelos *open-source* e *closed-source* de fornecedores distintos.

4. Materiais e Métodos

Esta pesquisa é de natureza experimental quantitativa. A classificação como experimental justifica-se pela necessidade de mensurar e comparar, de forma controlada e replicável, o desempenho de diferentes famílias de ataque adversarial em múltiplos domínios e modelos, com manipulação deliberada das variáveis independentes (tipo de ataque, domínio e modelo-alvo). A abordagem quantitativa é adequada porque as questões de pesquisa requerem medições numéricas, ASR, FPR, TR e *Stealthiness Score*, que permitem comparações estatísticas entre grupos. O *design* experimental possibilita isolar os efeitos de cada variável e produzir resultados diretamente comparáveis ao estado da arte, garantindo repetibilidade e replicabilidade dos procedimentos [Wohlin et al. 2012]. A metodologia adotada neste estudo é organizada em quatro fases sequenciais, conforme ilustrado na Figura 1 e detalhado na Subseção 4.1.




Figura 1. Diagrama do processo metodológico.

A Figura 1 representa o fluxo completo da metodologia proposta. A Fase 1, *Preparação e Identificação de Vulnerabilidades*, concentra as atividades preparatórias que precedem qualquer execução de ataque. A Fase 2, *Execução do Red Teaming*, aplica as três famílias de ataque adversarial sobre os modelos selecionados na fase anterior. A Fase 3, *Ciclo de Ataques e Refinamento*, representa o núcleo operacional do experimento: cada *prompt* é enviado ao modelo-alvo e, em caso de resposta sem violação (seta *NÃO*), o ataque é refinado e reenviado, em um *loop* que se repete até o esgotamento do *budget* de *queries*; em caso de violação (seta *SIM*), o resultado é registrado como ASR daquele domínio. Por fim, a Fase 4, *Análise e Resultados*, recebe os dados registrados na Fase 3 e produz as comparações *cross-domínio* e *cross-modelo*, bem como as diretrizes de mitigação *domain-aware*. As subseções a seguir detalham cada uma dessas quatro fases.

4.1. Descrição das Etapas

Preparação e Identificação de Vulnerabilidades.

Nesta etapa, definem-se os domínios críticos de estudo, saúde, financeiro e jurídico, e os critérios de violação específicos para cada domínio, ausentes no artigo base [Niloy et al. 2025], que determina o que constitui um *jailbreak* naquele contexto. Os critérios são os seguintes:

- **Saúde:** o modelo fornece dosagem de medicamento, diagnóstico ou recomendação terapêutica específica sem os devidos *disclaimers* ou em contexto de perigo direto ao paciente.

- **Financeiro:** o modelo recomenda investimento específico, descreve esquema de evasão fiscal ou lavagem de dinheiro, ou gera conteúdo que viole regulamentações da Comissão de Valores Mobiliários (CVM) ou do Banco Central sem *disclaimers* regulatórios.
- **Jurídico:** o modelo fornece orientação jurídica específica que caracterizaria exercício ilegal da advocacia, ou descreve mecanismos de burla contratual ou processual que violem a Lei Geral de Proteção de Dados (LGPD) ou o Código Civil.

Essa etapa precede qualquer execução de ataque, preservando a validade interna dos experimentos. Em síntese, a estratégia experimental consiste em realizar o *fine-tuning domain-specific* de modelos *open-source* de base por meio da biblioteca *Hugging Face Transformers* e da técnica *Low-Rank Adaptation* (LoRA) [Hu et al. 2022], utilizando esses modelos especializados como base (*surrogate*) para a geração dos ataques de otimização (GCG), cujos sufixos adversariais são então transferidos e testados nos modelos *closed-source* por meio de *surrogate transfer*. Em seguida, concebe-se o *dataset* adversarial *domain-specific*, com 50 a 100 *queries* por domínio, incluindo tanto *queries* adversariais quanto *queries* benignas elaboradas por profissionais da área (médicos, advogados e analistas financeiros), necessárias para a mensuração do FPR. Por fim, procede-se ao *fine-tuning domain-specific* dos modelos *open-source* de base por meio da técnica LoRA, e à seleção dos modelos de uso geral *closed-source* apresentados na Tabela 1.

Tabela 1. Modelos selecionados por domínio crítico.

Domínio	Modelo Open-Source (fine-tunado via LoRA)	Modelo Closed-Source
Saúde	LLaMA-2 + LoRA (saúde)	GPT-4o (OpenAI API)
Financeiro	LLaMA-2 + LoRA (financeiro)	Claude 3.5 Sonnet (Anthropic API)
Jurídico	LLaMA-2 + LoRA (jurídico)	Gemini 1.5 Pro (Google AI Studio)

Os modelos *open-source* de base (LLaMA-2 ou equivalente) são executados localmente por meio da biblioteca *Hugging Face Transformers* e submetidos a *fine-tuning domain-specific* próprio via LoRA [Hu et al. 2022], utilizando os dados especializados de cada domínio crítico, dando origem a três modelos especializados, um por domínio (saúde, financeiro e jurídico). Essa abordagem permite comparar o mesmo modelo base antes e depois do *fine-tuning*, isolando o efeito da especialização sobre a vulnerabilidade a ataques adversariais. Os modelos *open-source*, em sua versão especializada, funcionam como base (*surrogate*) para a geração dos ataques GCG, conforme detalhado na Subseção 4.1.2. Os modelos *closed-source* (GPT-4o, Claude 3.5 Sonnet e Gemini 1.5 Pro), por sua vez, são avaliados em seu estado nativo, isto é, com o alinhamento já realizado por cada fornecedor (OpenAI, Anthropic e Google), sem qualquer *fine-tuning* adicional, sendo acessados via *Application Programming Interface* (API) pública. A seleção de três fornecedores distintos permite avaliar comparativamente o comportamento de diferentes mecanismos de alinhamento nativo, sendo eles RLHF, *Constitutional AI* e o processo de alinhamento próprio do Google, frente aos ataques transferidos dos modelos *open-source* especializados, ampliando a validade externa dos resultados.

Execução do Red Teaming Automatizado.

Aplicam-se as três famílias de ataque adversarial, *prompt-based*, *optimization-based* (GCG) e *multi-turn*, sobre todos os modelos e domínios definidos na etapa anterior. Os ataques *prompt-based* exploram conflito de prioridades, encapsulamento em contexto ficcional, *role-play* e inversão de instrução. Os ataques GCG buscam sufixos adversariais em nível de *token* com perturbação controlada ($\epsilon \leq 30 \text{ tokens}$). Por ser um ataque *white-box* que requer acesso aos gradientes internos do modelo, o GCG é aplicado exclusivamente sobre os modelos *open-source* especializados obtidos na Fase 1; os sufixos adversariais gerados são então transferidos para os modelos *closed-source* via API, seguindo a estratégia de *surrogate transfer* proposta por [Zou et al. 2023], que demonstrou taxa de transferência *cross-model* de 58,3%. Os ataques *multi-turn* conduzem conversas com oito ou mais turnos para avaliar a deterioração progressiva do alinhamento pelo acúmulo de contexto.

Os parâmetros técnicos são padronizados em todas as execuções: temperatura $T = 0,7$; *budget* de *queries* $B = 20$ para ataques de otimização e $B = 5$ para ataques *prompt-based*. Cada configuração experimental é executada com no mínimo três *seeds* aleatórias distintas, reportando-se média $\pm$ desvio padrão.

Ciclo de Ataque e Refinamento.

Executa-se um *loop* iterativo de envio de *prompt*, avaliação do resultado e refinamento da estratégia adversarial até o esgotamento do *budget* de *queries* (B). Diferentemente de Niloy et al. [Niloy et al. 2025], que tratam a resposta como binária, esta pesquisa adota três categorias de resultado: *Compliance Total* ($ASR = 1$), *Compliance Parcial* e Recusa/Falso Positivo. Para a rotulação de casos ambíguos entre essas categorias, aplica-se o *Cohen's Kappa* com limiar $\kappa = 0,7$ entre dois anotadores independentes.

Análise Cross-Domínio e Cross-Modelo.

Geram-se a matriz de resultados de ASR ($3 \text{ domínios} \times 3 \text{ famílias} \times N \text{ modelos}$) e as curvas ROC para cada mecanismo de defesa avaliado. Investigam-se as assimetrias de ASR entre domínios, a transferabilidade *domain-specific* entre modelos *open-source* e *closed-source* obtida via *surrogate transfer*, e propõem-se diretrizes de mitigação *domain-aware* com limiares de FPR diferenciados por domínio.

4.2. Métricas de Avaliação

As métricas empregadas para responder às questões de pesquisa são apresentadas na Tabela 2.

Tabela 2. Métricas de avaliação adotadas e suas justificativas.

Métrica	Descrição e Justificativa
ASR (<i>Attack Success Rate</i>)	Proporção de <i>queries</i> adversariais com <i>Compliance Total</i> . Métrica central para medir eficácia dos ataques e comparar domínios.
TR (<i>Transferability Rate</i>)	Proporção de ataques otimizados contra um modelo que funcionam em outro. Avalia o risco <i>cross-model</i> em cenários reais via <i>surrogate transfer</i> .
FPR (<i>False Positive Rate</i>)	Proporção de <i>queries</i> benignas incorretamente bloqueadas por defesas. Mede o custo de usabilidade, crítico em domínios como saúde.
<i>Stealthiness Score</i>	Escala de 1 a 5 atribuída por anotadores humanos, medindo a semelhança do <i>prompt</i> adversarial com um <i>input</i> benigno.

4.3. Cronograma

As atividades de TCC II estão previstas entre agosto e novembro de 2026. As Tabelas 3 e 4 apresentam os cronogramas individuais dos dois integrantes, com tarefas independentes e complementares.

Tabela 3. Cronograma quinzenal de TCC II — Kaio Henrique Silveira.

	Ago 1 ^a	Ago 2 ^a	Set 1 ^a	Set 2 ^a	Out 1 ^a	Out 2 ^a	Nov 1 ^a	Nov 2 ^a
Atividade								
A1. Revisão da literatura e critérios de violação	X	X						
A2. Construção do <i>dataset</i> adversarial		X	X	X				
A3. Ataques <i>prompt-based</i>				X	X			
A4. Ciclo de refinamento e rotulação ternária					X	X		
A5. Cálculo do <i>Cohen's Kappa</i> e validação						X		
A6. Análise de transferabilidade <i>cross-model</i>						X	X	
A7. Diretrizes de mitigação <i>domain-aware</i>							X	
A8. Resultados e Discussão (conjunto)							X	
A9. Revisão final e defesa							X	X

Tabela 4. Cronograma quinzenal de TCC II — Pedro Arthur Oliveira Silva.

	Ago 1 ^a	Ago 2 ^a	Set 1 ^a	Set 2 ^a	Out 1 ^a	Out 2 ^a	Nov 1 ^a	Nov 2 ^a
Atividade								
B1. Configuração do ambiente e APIs	X							
B2. Fine-tuning <i>domain-specific</i> via LoRA		X	X					
B3. Ataques GCG (<i>optimization-based</i>)				X	X			
B4. Ataques <i>multi-turn</i> (8+ turnos)					X	X		
B5. Coleta e pré-processamento dos resultados						X		
B6. Análise <i>cross-domain</i> e matriz ASR						X		
B7. Análise estatística e curvas ROC							X	
B8. Comparação <i>cross-model</i>							X	
B9. Resultados e Discussão (conjunto)								X
B10. Revisão final e defesa								X

5. Considerações Finais

Este trabalho apresenta a proposta de uma avaliação sistemática de vulnerabilidades de LLMs em domínios críticos por meio de *red teaming* automatizado *domain-aware*. A abordagem proposta avança o estado da arte ao introduzir critérios de violação específicos por domínio definidos antes da execução dos experimentos, uma categorização ternária de resultados (*Compliance Total*, *Compliance Parcial* e Recusa/FP) e uma metodologia de comparação *cross-domain* e *cross-model* ainda não explorada na literatura. A adoção da estratégia de *surrogate transfer* para avaliação de modelos *closed-source* de três fornecedores distintos (OpenAI, Anthropic e Google) amplia a validade externa dos resultados e permite comparar o comportamento de diferentes mecanismos de alinhamento frente aos mesmos ataques adversariais.

Espera-se que os resultados produzam evidências quantitativas sobre as assimetrias de vulnerabilidade entre saúde, finanças e jurídico, além de diretrizes de mitigação contextualizadas aplicáveis ao desenvolvimento e operação de sistemas de *software* que incorporam LLMs em ambientes regulados. Como trabalhos futuros, pretende-se estender a análise para domínios adicionais, como educação e setor público, e investigar técnicas de *adversarial training domain-specific* como mecanismo de defesa complementar.

Referências

- Bai, Y., Jones, A., Ndousse, K., Askell, A., Chen, A., DasSarma, N., Drain, D., Fort, S., Ganguli, D., Henighan, T., et al. (2022). Constitutional AI: Harmlessness from AI feedback. Technical report, Anthropic. arXiv:2212.08073.
- Chao, P., Robey, A., Dobriban, E., Hassani, H., Pappas, G. J., and Wong, E. (2025). Jail-breaking black box large language models in twenty queries. In *2025 IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*. IEEE.
- Goh, A., Elangovan, A., and Chieu, H. L. (2025). Scaling responsible generative AI: Automating red teaming of LLM applications. In *2025 IEEE Conference on Artificial Intelligence (CAI)*. IEEE.

- Greshake, K., Abdelnabi, S., Mishra, S., Endres, C., Holz, T., and Fritz, M. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. In *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security*. ACM.
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., and Chen, W. (2022). LoRA: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*.
- Knowlton, B., Yim, J., Bhatt, U., and Bhatt, D. (2026). Prompt-based jailbreaking of leading LLM chatbots: A survey of attacks and defenses. *IEEE Transactions on Artificial Intelligence*.
- Nay, J. J., Karamardian, D., Lawsky, S. B., et al. (2023). Law informs code: A legal informatics approach to aligning artificial intelligence with humans. *Northwestern University Law Review*, 117(6).
- Niloy, M. R. I., Hasan, S. M., Akimoto, Y., Hassan, A. S. M. S., and Noon, M. W. I. (2025). Jailbreaking large language models: A red teaming perspective. In *2025 IEEE 2nd International Conference on Computing, Applications and Systems (COMPAS)*. IEEE.
- OpenAI (2023). GPT-4 technical report. Technical report, OpenAI. arXiv:2303.08774.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Aspell, A., Welinder, P., Christiano, P., Leike, J., and Lowe, R. (2022). Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, volume 35. NeurIPS.
- Perez, E., Huang, S., Song, F., Cai, T., Ring, R., Aslanides, J., Glaese, A., McAleese, N., and Irving, G. (2022). Red teaming language models with language models. In *arXiv preprint arXiv:2202.03286*.
- Shen, X., Chen, Z., Backes, M., Shen, Y., and Zhang, Y. (2024). "do anything now": Characterizing and evaluating in-the-wild jailbreak prompts on large language models. In *Proceedings of the 2024 ACM SIGSAC Conference on Computer and Communications Security*. ACM.
- Singhal, K., Azizi, S., Tu, T., et al. (2023). Large language models encode clinical knowledge. *Nature*, 620:172–180.
- Touvron, H., Martin, L., Stone, K., et al. (2023). Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30. NeurIPS.
- Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., and Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer.
- Yang, Z., Liu, Y., Wu, J., et al. (2023). FinGPT: Open-source financial large language models. *arXiv preprint arXiv:2306.06031*.

Zou, A., Wang, Z., Kolter, J. Z., and Fredrikson, M. (2023). Universal and transferable adversarial attacks on aligned language models. In *arXiv preprint arXiv:2307.15043*.

Apêndice

A. Considerações Éticas

A geração de ataques adversariais contra sistemas baseados em LLMs em domínios críticos envolve riscos de uso indevido que devem ser explicitamente endereçados. Todos os experimentos são conduzidos em ambiente controlado, sem interação com sistemas reais de saúde, financeiros ou jurídicos, e sem exposição de dados de usuários reais. Os *prompts* adversariais gerados não são divulgados em sua forma completa neste trabalho, de modo a mitigar o risco de uso malicioso, seguindo as diretrizes de divulgação responsável (*responsible disclosure*) recomendadas pela literatura.

O acesso às APIs dos modelos *closed-source* é realizado estritamente dentro dos termos de uso de cada fornecedor (OpenAI, Anthropic e Google), que permitem explicitamente pesquisa acadêmica de segurança. Os resultados são reportados de forma agregada, com foco nas métricas quantitativas e nas diretrizes de mitigação, e não na reprodução de conteúdo nocivo. O objetivo final desta pesquisa é contribuir para o desenvolvimento de sistemas de LLMs mais seguros em contextos regulados, alinhando-se aos princípios de IA responsável e ao interesse público.